关于量化代码的说明

1. 安装 easydict 库（**需要手动安装**）

首先将 easydict 文件夹解压

在终端中输入 conda activate pytorch，确保激活我们所实验的虚拟环境

输入 cd 命令进入到解压文件所在位置，比如 D://package//easydict-1.13

在终端中输入 python setup.py install 进行安装

2. 拷贝量化所需的 qqquantize 文件（**本次课分发的新代码中该步骤已完成，可直接使用新的代码工程**）

将压缩包解压后的 qqquantize 文件夹整体拷入 lenet（即上次课的代码工程的根目录）文件夹中

名称	修改日期	类型	大小
__MACOSX	2024/3/12 21:11	文件夹	
qqquantize	2024/3/12 21:11	文件夹	
quant_txt2img.py	2024/1/12 20:17	PY 文件	13 KB

3. 对模型进行量化，即增加如下代码到 run.py 文件中（本次课分发的新代码中该步骤已完成，可直接使用新的代码工程）

3.1 将如下部分增加到 run.py 文件开始的 import 部分。

from easydict import EasyDict as edict
from qqquantize.quantize import DEFAULT_QAT_MODULE_MAPPING, ModelConverter, fuse_conv_bn
from qqquantize.observers import FakeQuantize, toggle, MovingAverageMinMaxObserver, MinMaxObserver
import copy

代码截图参考如下：

```
from easydict import EasyDict as edict
from qqquantize.quantize import DEFAULT_QAT_MODULE_MAPPING, ModelConverter, fuse_conv_bn
from qqquantize.observers import FakeQuantize, toggle, MovingAverageMinMaxObserver, MinMaxObserver
import copy
```

3.2 增加如下代码对模型进行量化。

将以下代码增加到 net.eval 语句前，可通过点击 run.py 文件并按 shift+F3 键进行搜索

```
qconfig = edict({
    'activation': FakeQuantize.with_args(bits=8, observer=MinMaxObserver),
    'weight': FakeQuantize.with_args(bits=8, observer=MinMaxObserver),
    'bias': FakeQuantize.with_args(bits=8, observer=MinMaxObserver)
})
mapping = copy.deepcopy(DEFAULT_QAT_MODULE_MAPPING)
#首先是实例化一个 ModelConverter，此时调用的是__init__

converter = ModelConverter(qconfig, mapping=mapping)#建立一个量化的转换器

#下面开始调用__call__ ,然后 call 中分别调用 self._propagate_qconfig(model) 和 self._convert(model, device)
converter(net)
```

toggle(net, quantize=True, observer=True, calc_qparam=True)　　converter(model)

toggle(model,quantize=True, observer=True,calc_qparam=True)

代码截图参考如下：

```
qconfig = edict({
    'activation': FakeQuantize.with_args(bits=8, observer=MinMaxObserver),
    'weight': FakeQuantize.with_args(bits=8, observer=MinMaxObserver),
    'bias': FakeQuantize.with_args(bits=8, observer=MinMaxObserver)
})
mapping = copy.deepcopy(DEFAULT_QAT_MODULE_MAPPING)
#首先是实例化一个ModelConverter，此时调用的是__init__
converter = ModelConverter(qconfig, mapping=mapping)#建立一个量化的转换器
#下面开始调用__call__，然后call中分别调用 self._propagate_qconfig(model)和self._
converter(net)
toggle(net, quantize=True, observer=True, calc_qparam=True)
```

```
net.eval()
total_correct = 0
```